

Parcial computacional sobre Test de Hipótesis: Correlacionados

Métodos Estadísticos en Física Experimental

2023

1 Enunciado

Una forma de crear pares de fotones correlacionados consiste en hacer incidir un haz laser sobre un cristal birrefringente. En él puede tener lugar el proceso de Conversión Paramétrica Espontánea Descendente mediante el cuál un fotón decae en otros dos. Vía las leyes de conservación de energía y momento, sabiendo con que energía y ángulo fue emitido uno de los fotones, es posible conocer la energía y ángulo con que fue emitido su compañero. Los pares de fotones así generados se encuentran entonces correlacionados y es por eso que pueden utilizarse en muchas aplicaciones interesantes. Sin embargo, una de las limitaciones experimentales está impuesta por la existencia de un fondo de fotones no correlacionados.

2 Consignas

Se quiere hacer un test de hipótesis para descartar la premisa de que dos muestras de fotones no se encuentran correlacionadas.

1. **Generando los datos:** Para construir el conjunto de datos con los que va a trabajar, genere $n=100$ realizaciones de una variable aleatoria con distribución de Poisson($k, \mu_1=100$) correspondiente al número de pares de fotones correlacionados obtenidos luego de un segundo de experimento. Llamaremos a esta la muestra SA. Haga una copia de estos n resultados obtenidos, lo que conformará la muestra SB idéntica a SA.
2. **Generando el fondo:** Genere ahora $n=100$ realizaciones de una variable aleatoria con distribución de Poisson($k, \mu_2=50$) correspondiente al número de pares de fotones **no** correlacionados obtenidos luego de un segundo de experimento. Llamaremos a esta la muestra FA. Esta vez, en lugar de hacer una copia, vuelva a generar n realizaciones de Poisson($k, \mu_2=50$) conformando la muestra FB.
3. **Contaminando los datos:** Construya la muestra MA como la suma de SA y FA y lo propio para construir MB. Calcule luego la correlación entre MA y MB.
4. **El estadístico** Adaptando los items anteriores según corresponda, construya así la distribución del estadístico *correlación entre dos muestras* cuando H_0 es cierta a partir de $N=1000$ realizaciones.


5. **El test:** Dada la distribución obtenida en el punto anterior y para una significancia $\alpha=0.05$, indique la zona de rechazo de la hipótesis nula H_0 : *Los fotones no están correlacionados*.
6. **Errores:** Cuantifique el error Tipo I y el error Tipo II que se comete al usar el test en cuestión.
7. **Potencia:** Calcule la potencia del test para diferentes valores de μ_2 (con hacerlo para 10 valores diferentes basta).
8. **p-valor:** Genere una muestra MA y MB con los valores inicialmente sugeridos para μ_1 y μ_2 simulando así un único experimento. Aplique el test construido anteriormente y calcule el p-valor correspondiente al resultado obtenido. ¿Cual es la máxima significancia que podría haberle pedido al test tal que no rechace la hipótesis nula?
9. **Histograma de p-valor:** Repita 1000 veces el item anterior y grafique el histograma de los p-valores. Discuta que esperaba encontrar si la hipótesis nula fuese cierta y como se diferencia de eso lo que realmente observó.

Referencia Test motivado por el trabajo de Tesis doctoral de Sebastian Bordakevich, Guadalupe Aparicio, la tesis de grado de Muriel Bonetto y la tesis doctoral de Agustina Magnoni. Es además una de las líneas de investigación en LAMBDA, DF-UBA.

3 Generalidades


1. Indicar nombre, apellido, libreta o DNI en el informe.
2. Dar una descripción clara y precisa de la metodología utilizada.
3. Incluir todos los gráficos como figuras con sus correspondientes leyendas.
4. Justifique las hipótesis en la que se sustenten sus resultados y discuta los resultados obtenidos.
5. La fecha límite para la entrega es el martes 11 de julio a las 11 hs.
6. Enviar por mail a dariorodriguesfm@gmail.com. Nombrar al archivo de la siguiente manera: TH-SuApellido.pdf y adjuntar en el mismo mail los códigos desarrollados. Utilizar como asunto del mail: "TH-rho".
7. Por consultas sobre interpretación de los enunciados escribir al grupo: mefe-1c-2023@googlegroups.com, así todos tienen acceso a todas las respuestas.

■1) Tomando entonces la cantidad de realización de la distribución Poissoniana con $\mu_1 = 100$, podemos armar un histograma que nos permita ver las realizaciones aleatorias que corresponderían a la cantidad de numero de pares de fotones correlacionados. Tomamos luego que $SA = SB$, de forma que ambos histogramas coinciden



Veamos que obviamente los histogramas de ambas distribuciones coinciden porque pedimos que fuesen iguales. Luego podemos tomar el error de la cantidad de veces de ocurrencia de cada bin como una distribución poissoniana (Al haber muchos bins y cada uno de estos con una baja probabilidad de que algún valor entre dentro), donde por tanto el error de cada uno de estos se toma como la raíz de la cantidad de ocurrencias contenidas, siendo posteriormente normalizado junto al histograma. Vemos que estos intervalos explican bien las fluctuaciones estadísticas al contener el valor real de la distribución la mayoría de las veces, dando un alto *C.L.* (Para el resto del informe se toma este mismo criterio de errores para los intervalos de valores).

■2) Haciendo un proceso análogo, genero los números correspondientes a los pares de fotones no correlacionados FA , luego para construir los valores de FB vuelvo a generar números de la misma distribución Poissoniana con $\mu_2 = 50$



Vemos que ambos histogramas difieren a pesar de haber venido de la misma distribución dada la poca cantidad de realizaciones pedidas. De esta forma se da que la lista de valores obtenidos para FA y FB difieren de igual forma. Y haciendo un análisis análogo al anterior, vemos que la estimación poissoniana de las fluctuaciones estadísticas que explican los intervalos de error es buena también (como era de esperar).

■3) Ahora que tenemos las muestras **MA** y **MB**, podemos estudiar la correlación de estas cantidades viendo sus expresiones **MA** = **FA** + **SA** ; **MB** = **FB** + **SB**. Luego como **SA** = **SB**, puedo despejar una en función de la otra para poder ver como una de las cantidades va a ser sensibles a las variaciones de la otra

$$MA = FA + SB = FA + MB - FB$$


De esta relación entonces, se intuye que la correlación entre estos sets de datos va a ser no nula, debido a que el cálculo de las covarianzas va a ser no nulo al tener una dependencia explícita **MA** de **MB**. Para el cálculo exacto entonces, a partir de la media de $\overline{MA} = \sum_i^n \frac{MA_i}{n}$ y $\overline{MB} = \sum_j^n \frac{MB_j}{n}$, podemos calcular entonces la varianza usando el estimador $\hat{S}_{MA}^2 = \frac{\sum (MA - \overline{MA})^2}{n-1}$; $\hat{S}_{MB}^2 = \frac{\sum (MB - \overline{MB})^2}{n-1}$ y luego la covarianza, $\hat{S}_{cov}^2 = \frac{\sum (MA - \overline{MA})(MB - \overline{MB})}{n-1}$.

(Notar que el termino $n-1$ viene de perder un grado de libertad al estimar la media de la distribución usando la media muestral)

Finalmente, usando el coeficiente de correlación de Pearson, $correlacion = \frac{\hat{S}_{cov}^2}{\sigma_{MA} * \sigma_{MB}} = 0.58$. Siendo este el valor de correlación dado para **N** = 1 realizaciones sobre las variables **MA** y **MB**.

■4) Para generar el estadístico adecuado sobre la cual voy a construir mi hipótesis **H₀** de que no están relacionados los fotones; tomo los mismos pasos seguidos en los incisos anteriores con la excepción de que **SA** ≠ **SB**, si no que esta ultima va a ser una nueva realización de la misma distribución.


Notemos así que el despeje hecho en el inciso anterior no lo podemos hacer, de forma que la covarianza entre estas cantidades y por tanto la correlación debe tender a ser nula si no tomamos en cuenta fluctuaciones estadísticas. Pero en definitiva la esperanza de este estadístico debe ser 0.




Efectivamente vemos que la distribución dada por el histograma está centrada en el cero. Además, dado el teorema central de limite, al haber tomado **N** = 1000 realizaciones, esta distribución dada para la correlación entre las dos listas tiende a ser una gaussiana y por tanto su valor central se puede tomar como su esperanza.

Para trabajar con este test las barras de error son irrelevantes. Por tanto, opto por no ponerlas, ya que no me aportan nada de información relevante para rechazar o no **H₀**. Esto debido a que quiero comprobar la veracidad de esta realización específica de las variables dado que en principio no conocemos la distribución gaussiana asociada a la correlación de las variables **MA** y **MB**.

Se le atribuyen los valores más lejanos de la media a fluctuaciones que coincidieron tal que la correlación entre las listas de datos parecería tener correlación mayor a 0 en algunas de las **N** = 1000 iteraciones. Donde podemos ejemplificar mostrando algunas de las correlaciones de estas **N** iteraciones,




Correlación negativa (-0.19)



Correlación positiva (0.20)

■5) Para la construcción del test, debemos identificar los valores comunes de las anomalías estadísticas, es decir los valores más raros y para estos colocar un criterio α que me va a determinar la zona de rechazo. Esta se usa para denotar un criterio de rechazo de la hipótesis nula H_0 dada la rareza estadística de que aparezca una correlación observada de estos valores.

Habiendo introducido esto entonces queda claro que los valores que quiero denotar como zona de rechazo son las colas de la distribución (los valores más alejados de la media), pero teniendo en cuenta que dada la construcción de este ejercicio, mi hipótesis H_1 (fotones están correlacionados, que surge como alternativa de H_0) toma solo valores positivos de correlación, por tanto solo me interesa tomar la cola hacia la derecha, que corresponde a los valores de correlación positivos lejanos al 0. Construyo entonces



Donde como dijimos anteriormente, la zona de rechazo está dada tomando como criterio $\alpha = 0.05$, lo cual quiere decir que se suman los bins desde la derecha hasta que sumen en total una probabilidad igual o menor a mi criterio de rechazo α , formando un área completa desde el último bin sumado hasta $+\infty$.

Notemos que tomando esta zona de rechazo respecto al criterio de aceptación pedido. Debido a que seguiría rechazando aquellos p_{valores} menores a mi criterio de aceptación, es decir para observaciones sobre la zona roja. Luego para valores observables que caigan en mi zona azul, van a tener como mínimo un $p_{\text{valor}} > 0.05$ que sería mi criterio de aceptación, al tener que sumar el área de ese bin con la correspondiente al área de rechazo que dijimos es la mayor posible sin superar el criterio α , de forma que sumando cualquier otro bin, supero el valor requerido como mínimo de aceptación 0.05 .

Es interesante ver que, comparando con el ejemplo mostrado en el inciso anterior en el cual se mostró una correlación de 0.20, esta se consideraría en la zona de rechazo a pesar de haber provenido de la distribución dada por mi estadístico sin correlación. Por lo tanto, este criterio de rechazo puede llegar a rechazar valores que en realidad si provenían de una distribución que no pudiese rechazar H_0 .


■6) Puedo conseguir los errores de tipo 1 solo conociendo el criterio de aceptación para mi hipótesis nula H_0 . Sería la probabilidad de rechazar H_0 en caso tal de que la hipótesis sea verdadera (tal y como se introdujo al final del inciso anterior). Para calcularlo solo se toma entonces

$$\int_{C_{\text{crítico}}}^{\infty} f(C|H_0) dC = \alpha = \sum_{C_{\text{crítico}}}^{\infty} f(C|H_0) = 0.042$$

En casos de distribuciones discretas, es posible que no consiga una cota que me de como cola derecha el valor exacto de significancia que quiero $\alpha = 0.05$, por tanto, me quedo al bin mas cercano por debajo como se explico en el inciso anterior.

Para el error del tipo 2, necesito disponer de una hipótesis alternativa a H_0 , llamada H_1 . Estas hipótesis son complementarias, porque rechazar H_0 es lo mismo que aceptar H_1 . Teniendo en cuenta que mi hipótesis nula es que los fotones no estén correlacionados, mi hipótesis alternativa va a ser que estén correlacionados.

De esta forma, y usando la distribución calculada en los primeros incisos (Donde $SA = SB$), puedo conseguir el error de tipo 2 (β) para una hipótesis alternativa, el cual me va a dar la probabilidad de aceptar H_0 cuando en realidad esta no es verdadera.



Para despejar el valor de β entonces se plantea que

$$\sum_{C_{\text{crítico}}}^{\infty} f(C|H_1) = 1 - \beta \quad \rightarrow \quad \beta = 1 - \sum_{C_{\text{crítico}}}^{\infty} f(C|H_1) = 0$$


Vemos que el valor de error tipo 2 es nulo, esto se debe a que las distribuciones no se solapan en ningún valor, y por lo tanto no se solapan en valores fuera de la zona de rechazo para H_0 , haciendo que sea imposible el aceptar H_0 cuando en realidad esta no era verdadera, ante la hipótesis alternativa H_1 .

■7) El cálculo de potencia depende de la hipótesis alternativa H_1 que esté utilizando, y esta nos permite conocer la probabilidad de rechazar una hipótesis en el caso de que sea falsa. Se calcula como

$$Poder = \sum_{C_{\text{crítico}}}^{\infty} f(C|H_1)$$

Es decir que es una cuenta totalmente análoga a la del inciso anterior, con la diferencia que me interesa despejar el poder y no el error tipo 2 (β). Ahora bien, como dijimos este valor depende de H_1 y por tanto depende de la distribución de valores de la cual sale H_1 . Si tomo diferentes valores de $\mu_2 =$

[30, 50, 70, 120, 180, 250, 400, 700, 1000, 5000] podemos ver como va a ser la distribución dada para H_1 frente a mi H_0 original.



Donde solo agrego al ploteo 4 de estos valores para mostrar la tendencia de la distribución ante variaciones de μ_2 . De los ploteos notamos un desplazamiento hacia el origen, lo cual se traduciría en un decremento en la correlación media de las variables para H_1 . Usando entonces la definición de poder, es decir integrando a partir de la zona de rechazo de H_0 hacia la cota superior de valores de correlación, tendremos los siguientes resultados


μ_2	<i>Poder</i>	β
30	1	0
50	1	0
70	1	0
120	1	0
180	0.99	0.01
250	0.94	0.06
400	0.74	0.26
700	0.45	0.55
1000	0.30	0.70
5000	0.14	0.86

Esto se traduce entonces en un aumento del error de tipo 2 si aumentamos μ_2 , al parecerse más la distribución de H_0 con la de H_1 , disminuyendo el poder de el test al no poder diferenciar de estas dos hipótesis. Ahora, el motivo por el cual H_1 tiende a H_0 con valores grande de μ_2 es porque recordando la forma de MA y MB .

$$MA = FA + SA ; MB = FB + SB$$


Vemos que el termino correlativo $SA = SB$ se hace mucho más pequeño al provenir de una distribución con esperanza $\mu_1 = 100$ mucho menor que μ_2 para grandes valores. Por lo tanto, la correlación de estos conjuntos MA y MB tiene a hacerse nula, debió a que el termino más pequeño prácticamente es despreciable, haciendo que a efectos prácticos tengamos dos generaciones para valores de FA y FB de la misma distribución. No teniendo entonces relevancia los términos SA y SB .

Me pareció interesante probar con valores mucho mayores de μ_2 respecto a $\mu_1 = 100$. Esto nos permite ver con mayor claridad la tendencia hacia el origen de H_1 con μ_2 grandes.



Donde podemos ver que efectivamente es cierto el que los valores de correlación positiva se hacen despreciables para estos valores tan grandes de generaciones para los fondos **FA** Y **FB**.

■8) Manteniéndonos en los valores $\mu_1 = 100$, $\mu_2 = 50$ esperamos una relación dada como en el inciso 6 entre H_0 y H_1 , de forma que este test es bueno para determinar el rechazo o no de H_0 al tener nulo error de tipo 2 (β). Generando una muestra que nos dé un valor de correlación para **MA** y **MB**, llegamos a



Aplicando entonces el test conseguido anteriormente, es decir usando los criterios de significancia del error tipo 1 como comparativa frente al valor observado, buscando entonces cual es la probabilidad de haber observado el valor experimental dado o uno más raro que este (es decir el p_{valor}). Esto lo calculamos viendo


$$\sum_{C_{obs}}^{\infty} f(C|H_0) = p_{valor} = 0$$

Este valor se da porque la distribución del estimador no llega a tener valores cercanos al observado bajo esta hipótesis nula, de forma que solo puedo estimar como $p_{valor} = \frac{1}{N}$ donde N son la cantidad de datos dados para la formación de H_0 . Esto debido a que sé que evaluando N realizaciones, ninguna llega a estar en el bin asociado a la cantidad observada, de esta forma solo puedo decir que necesito al menos $\frac{1}{N}$ valores para llegar algún valor significativo de p_{valor} , es decir darle una cota inferior a los valores que puede tomar este.


Luego, tomando el criterio de aceptación $\alpha = 0.05$, decimos que si $p_{valor} < 0.05$ entonces rechazamos la hipótesis H_0 . Esto debido a que es muy poco probable el hecho de haber conseguido este valor, si es verdad que la hipótesis nula fuese cierta. Y luego si $p_{valor} > 0.05$ no se puede rechazar H_0 .

En este caso en particular, la significancia máxima que podría haberse tomado tal que el test no rechace la hipótesis sería tomar una significancia dada por el valor estimado como mínimo de $p_{valor} = \frac{1}{N} = 0.001$ para este inciso.

■9) Repitiendo $N = 1000$ veces, y viendo los valores de correlación observada para cada muestra de MA y MB con los valores originales $\mu_1 = 100$ y $\mu_2 = 50$; al que posteriormente se le sacaría el p_{valor} a cada una de estas observaciones siguiendo el proceso análogo al inciso anterior; podríamos armar un histograma con los valores de p_{valor} dado como




Donde todos los valores coinciden en el 0. En particular quise ver si aumentando el número de entradas de la distribución dada por H_0 , es decir aumentar la cantidad de experimentos, puedo hacer que la distribución llegue a acercarse al conjunto de valores observados para generar un valor integrado del p_{valor} en vez de una cota mínimo. Así,



Donde vemos que tomando $N = 50000$, la distribución dada para H_0 sigue sin tomar valores cercanos a ninguno de los observados (ploteamos alguno de los 1000), de forma que la estimación de p_{valor} para este observado va a ser $\frac{1}{N} = \frac{1}{1000} = 1.0 \times 10^{-3}$ para el caso pedido por el inciso, o $\frac{1}{N} = 2.0 \times 10^{-5}$ para esta última cantidad de experimentos.

Esta distribución de valores de p_{valor} se debe al poder de mis test si suponemos μ_1 y μ_2 originales, el cual puede entonces rechazar mi hipótesis nula cada vez que algún valor observado provenga de H_1 . Lo cual era de esperarse debido a que sabemos que los fotones en realidad estaban correlacionados.


Para ver que hubiese encontrado si la hipótesis nula fuese cierta, me propuse a generar valores de MA y MB sin poner la condición de correlación $SA = SB$. Luego generando $N = 20000$ valores, y calculando la correlación de estos, llegamos al histograma de los p_{valor} s



Notar que esta vez sí incluimos la barra de errores para el histograma, debido a que quiero comprobar la veracidad de que estos vienen de una distribución uniforme $U:[0,1]$. Además, por completitud agregue una banda roja que indica aquellos valores de p_{valor} que serían rechazados por el criterio de este test

Veamos que existe una tendencia a una uniforme, cosa que esperaría debido a que la distribución del p_{valor} bajo una hipótesis nula es una uniforme de valores $U: [0, 1]$, es decir que tiene valores equiprobables de valer entre $[0, 1]$.

Si graficamos un par de las $N = 20000$ realizaciones sobre mi hipótesis nula, vemos que los valores de generación perfectamente pueden provenir de esta distribución asociada.



De esta forma, la distribución del p_{valor} esta dada por la probabilidad de obtener un valor tan raro como el observado o incluso más raro, la cual es igual en cualquier punto a lo largo de la distribución, al ser cierta H_0 y que las realizaciones provengan de esta distribución. Esta simetría es lo que da lugar a la uniformidad del p_{valor} con H_0 verdadera.

Finalmente, comparando la distribución del p_{valor} para las realizaciones del inciso 8 con el p_{valor} proveniente de una hipótesis nula verdadera, descartamos la hipótesis H_0 de que los fotones no están correlacionados.